Reiknirit Ahos og Corasicks (1975)

Bergur Snorrason

7. apríl 2022

▶ Gerum ráð fyrir að við séum með stafróð Σ , streng s og lista af n strengjum p, þar sem j-ti strengurinn kallast p_j .

- ▶ Gerum ráð fyrir að við séum með stafróð Σ , streng s og lista af n strengjum p, þar sem j-ti strengurinn kallast p_j .
- ▶ Látum |s| tákna lengd strengsins s og $|p| = |p_1| + \cdots + |p_n|$.

- ▶ Gerum ráð fyrir að við séum með stafróð Σ , streng s og lista af n strengjum p, þar sem j-ti strengurinn kallast p_j .
- Látum |s| tákna lengd strengsins s og $|p| = |p_1| + \cdots + |p_n|$.
- ▶ Við viljum finna alla hlutstrengi s sem eru í listanum p.

- ▶ Gerum ráð fyrir að við séum með stafróð Σ , streng s og lista af n strengjum p, þar sem j-ti strengurinn kallast p_j .
- ▶ Látum |s| tákna lengd strengsins s og $|p| = |p_1| + \cdots + |p_n|$.
- ▶ Við viljum finna alla hlutstrengi s sem eru í listanum p.
- ▶ Við getum notað reiknirit Knuths, Morrisar og Pratts *n* sinnum.

- ▶ Gerum ráð fyrir að við séum með stafróð Σ , streng s og lista af n strengjum p, þar sem j-ti strengurinn kallast p_j .
- ▶ Látum |s| tákna lengd strengsins s og $|p| = |p_1| + \cdots + |p_n|$.
- ▶ Við viljum finna alla hlutstrengi s sem eru í listanum p.
- ▶ Við getum notað reiknirit Knuths, Morrisar og Pratts *n* sinnum.
- ▶ Þessi aðferð hefur tímaflækjuna $\mathcal{O}(n \cdot |s| + |p|)$.

- ▶ Gerum ráð fyrir að við séum með stafróð Σ , streng s og lista af n strengjum p, þar sem j-ti strengurinn kallast p_j .
- ▶ Látum |s| tákna lengd strengsins s og $|p| = |p_1| + \cdots + |p_n|$.
- ▶ Við viljum finna alla hlutstrengi s sem eru í listanum p.
- ▶ Við getum notað reiknirit Knuths, Morrisar og Pratts *n* sinnum.
- ▶ Þessi aðferð hefur tímaflækjuna $\mathcal{O}(n \cdot |s| + |p|)$.
- Reiknirit Ahos og Corasicks bætir þetta.

ightharpoonup Byrjum á að setja all strengina í p inn í forstrengstré T.

- **b** Byrjum á að setja all strengina í p inn í forstrengstré T.
- ▶ Við viljum síðan búa til stöðuvél úr *T*.

- ightharpoonup Byrjum á að setja all strengina í p inn í forstrengstré T.
- Við viljum síðan búa til stöðuvél úr T.
- Hnútarnir í trénu eru stöðurnar, en okkur vantar að finna færslur fyrir hverja stöðu og bókstaf í Σ.

- **b** Byrjum á að setja all strengina í p inn í forstrengstré T.
- Við viljum síðan búa til stöðuvél úr T.
- Hnútarnir í trénu eru stöðurnar, en okkur vantar að finna færslur fyrir hverja stöðu og bókstaf í Σ.
- Gerum ráð fyrir að við séum í hnút v í T og viljum færast fyrir staf c í Σ.

- ▶ Byrjum á að setja all strengina í p inn í forstrengstré T.
- Við viljum síðan búa til stöðuvél úr T.
- Hnútarnir í trénu eru stöðurnar, en okkur vantar að finna færslur fyrir hverja stöðu og bókstaf í Σ.
- Gerum ráð fyrir að við séum í hnút v í T og viljum færast fyrir staf c í Σ.
- ► Ef það er leggur í T úr v merktur með c þá ferðumst við eftir honum.

- Byrjum á að setja all strengina í p inn í forstrengstré T.
- Við viljum síðan búa til stöðuvél úr T.
- Hnútarnir í trénu eru stöðurnar, en okkur vantar að finna færslur fyrir hverja stöðu og bókstaf í Σ.
- ▶ Gerum ráð fyrir að við séum í hnút v í T og viljum færast fyrir staf c í Σ .
- Ef það er leggur í T úr v merktur með c þá ferðumst við eftir honum.
- Annars þurfum við að fara aftur í hnút w þannig að strengurinn sem svarar til w er bakstrengur strengsins sem svarar til v.

- ▶ Byrjum á að setja all strengina í p inn í forstrengstré T.
- Við viljum síðan búa til stöðuvél úr T.
- Hnútarnir í trénu eru stöðurnar, en okkur vantar að finna færslur fyrir hverja stöðu og bókstaf í Σ.
- Gerum ráð fyrir að við séum í hnút v í T og viljum færast fyrir staf c í Σ.
- Ef það er leggur í T úr v merktur með c þá ferðumst við eftir honum.
- Annars þurfum við að fara aftur í hnút w þannig að strengurinn sem svarar til w er bakstrengur strengsins sem svarar til v.
- ▶ Við viljum hafa strenginn w sem lengstan (með öðrum orðum viljum við fara sem styst aftur).

- **b** Byrjum á að setja all strengina í p inn í forstrengstré T.
- Við viljum síðan búa til stöðuvél úr T.
- Hnútarnir í trénu eru stöðurnar, en okkur vantar að finna færslur fyrir hverja stöðu og bókstaf í Σ.
- Gerum ráð fyrir að við séum í hnút v í T og viljum færast fyrir staf c í Σ.
- Ef það er leggur í T úr v merktur með c þá ferðumst við eftir honum.
- Annars þurfum við að fara aftur í hnút w þannig að strengurinn sem svarar til w er bakstrengur strengsins sem svarar til v.
- ▶ Við viljum hafa strenginn w sem lengstan (með öðrum orðum viljum við fara sem styst aftur).
- ▶ Í hvern hnút bætum við við legg sem svarar til slíkrar færslu.

- Byrjum á að setja all strengina í p inn í forstrengstré T.
- Við viljum síðan búa til stöðuvél úr T.
- Hnútarnir í trénu eru stöðurnar, en okkur vantar að finna færslur fyrir hverja stöðu og bókstaf í Σ.
- Gerum ráð fyrir að við séum í hnút v í T og viljum færast fyrir staf c í Σ.
- Ef það er leggur í T úr v merktur með c þá ferðumst við eftir honum.
- Annars þurfum við að fara aftur í hnút w þannig að strengurinn sem svarar til w er bakstrengur strengsins sem svarar til v.
- ▶ Við viljum hafa strenginn w sem lengstan (með öðrum orðum viljum við fara sem styst aftur).
- ▶ Í hvern hnút bætum við við legg sem svarar til slíkrar færslu.
- ▶ Við köllum þessa leggi bakstrengsleggi (e. suffix links).

- **b** Byrjum á að setja all strengina í p inn í forstrengstré T.
- Við viljum síðan búa til stöðuvél úr T.
- Hnútarnir í trénu eru stöðurnar, en okkur vantar að finna færslur fyrir hverja stöðu og bókstaf í Σ.
- ▶ Gerum ráð fyrir að við séum í hnút v í T og viljum færast fyrir staf c í Σ .
- Ef það er leggur í T úr v merktur með c þá ferðumst við eftir honum.
- Annars þurfum við að fara aftur í hnút w þannig að strengurinn sem svarar til w er bakstrengur strengsins sem svarar til v.
- ▶ Við viljum hafa strenginn w sem lengstan (með öðrum orðum viljum við fara sem styst aftur).
- ▶ Í hvern hnút bætum við við legg sem svarar til slíkrar færslu.
- ▶ Við köllum þessa leggi bakstrengsleggi (e. suffix links).
- ► Takið eftir að þeir eru í raun óháðir bókstafnum c.

- Byrjum á að setja all strengina í p inn í forstrengstré T.
- Við viljum síðan búa til stöðuvél úr T.
- Hnútarnir í trénu eru stöðurnar, en okkur vantar að finna færslur fyrir hverja stöðu og bókstaf í Σ.
- ▶ Gerum ráð fyrir að við séum í hnút v í T og viljum færast fyrir staf c í Σ .
- Ef það er leggur í T úr v merktur með c þá ferðumst við eftir honum.
- Annars þurfum við að fara aftur í hnút w þannig að strengurinn sem svarar til w er bakstrengur strengsins sem svarar til v.
- ▶ Við viljum hafa strenginn w sem lengstan (með öðrum orðum viljum við fara sem styst aftur).
- ▶ Í hvern hnút bætum við við legg sem svarar til slíkrar færslu.
- Við köllum þessa leggi bakstrengsleggi (e. suffix links).
- Takið eftir að þeir eru í raun óháðir bókstafnum c.
- Við látum bakstrengslegg rótarinn benda á sjálfa sig.



► Hvernig finnum við alla bakstrengsleggina?

- ► Hvernig finnum við alla bakstrengsleggina?
- ► Við notum kvika bestun.

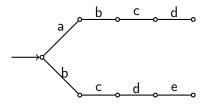
- Hvernig finnum við alla bakstrengsleggina?
- Við notum kvika bestun.
- Látum f(w, c) tákna færslu úr stöðu w með staf c og g(w) tákna bakstrengslegg w.

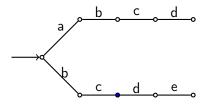
- Hvernig finnum við alla bakstrengsleggina?
- Við notum kvika bestun.
- Látum f(w, c) tákna færslu úr stöðu w með staf c og g(w) tákna bakstrengslegg w.
- ▶ Gerum einnig ráð fyrir að foreldri v sé p og f(p, a) = v.

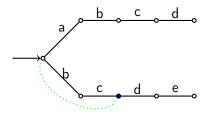
- Hvernig finnum við alla bakstrengsleggina?
- Við notum kvika bestun.
- Látum f(w, c) tákna færslu úr stöðu w með staf c og g(w) tákna bakstrengslegg w.
- ▶ Gerum einnig ráð fyrir að foreldri v sé p og f(p, a) = v.
- Við sjáum þá að g(v) = f(g(p), a).


- Hvernig finnum við alla bakstrengsleggina?
- Við notum kvika bestun.
- Látum f(w, c) tákna færslu úr stöðu w með staf c og g(w) tákna bakstrengslegg w.
- Gerum einnig ráð fyrir að foreldri v sé p og f(p, a) = v.
- Við sjáum þá að g(v) = f(g(p), a).
- Með öðrum orðum förum við upp í foreldrið, ferðumst eftir bakstrenglegg þaðan og færum okkur í stöðuvélinni eftir a.


- Hvernig finnum við alla bakstrengsleggina?
- Við notum kvika bestun.
- Látum f(w, c) tákna færslu úr stöðu w með staf c og g(w) tákna bakstrengslegg w.
- Gerum einnig ráð fyrir að foreldri v sé p og f(p, a) = v.
- Við sjáum þá að g(v) = f(g(p), a).
- Með öðrum orðum förum við upp í foreldrið, ferðumst eftir bakstrenglegg þaðan og færum okkur í stöðuvélinni eftir a.
- Við höfum þá rakningarformúlu sem við getum notað til að reikna bakstrengshlekkina.




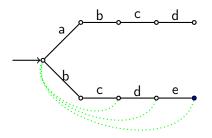


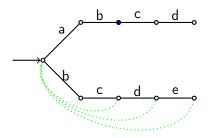








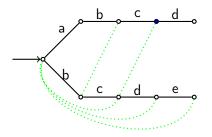





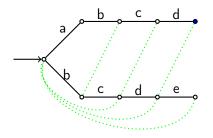








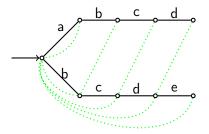




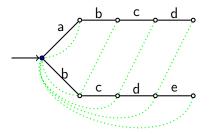
▶ Í T merkjum við lokastöður þar sem strengir enda.

- ▶ Í T merkjum við lokastöður þar sem strengir enda.
- ▶ Við ferðumst svo í gegnum strenginn s og hliðrum stöðvélinni miðað við stafina í s.

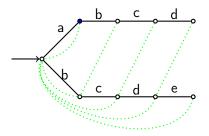
"abcdcdeaaabcdeabcxab"



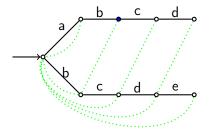
"abcdcdeaaabcdeabcxab"



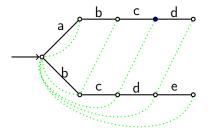
"bcdcdeaaabcdeabcxab"



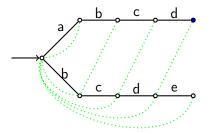
"cdcdeaaabcdeabcxab"



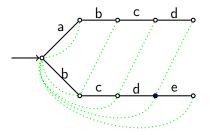
"dcdeaaabcdeabcxab"



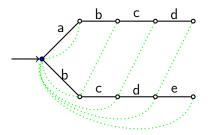
"cdeaaabcdeabcxab"




"cdeaaabcdeabcxab"




"cdeaaabcdeabcxab"



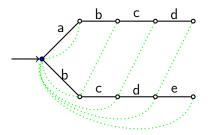
"deaaabcdeabcxab"



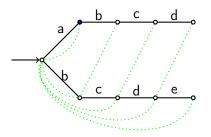
"eaaabcdeabcxab"



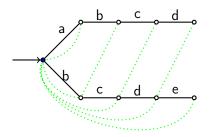
"aaabcdeabcxab"



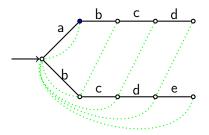
"aabcdeabcxab"



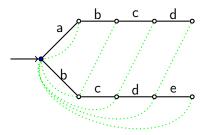
"aabcdeabcxab"



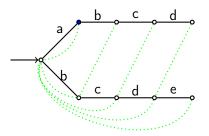
"abcdeabcxab"



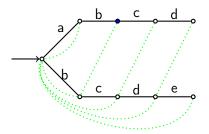
"abcdeabcxab"



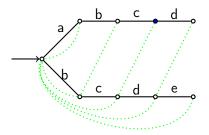
"bcdeabcxab"



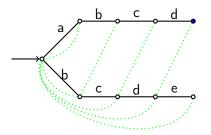
"cdeabcxab"



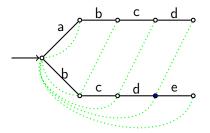
"deabcxab"




"eabcxab"




"eabcxab"




"abcxab"



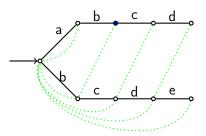
"abcxab"



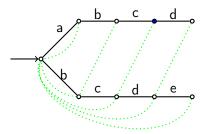
"bcxab"




"cxab"



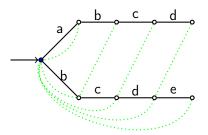
,,xab''

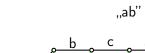


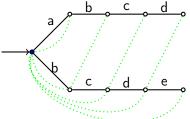
,,xab''

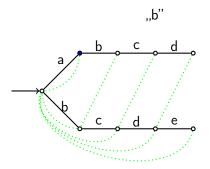


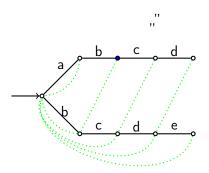
,,xab''

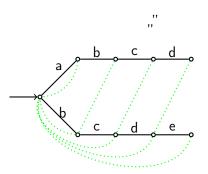













Ljóst er að alltaf þegar við erum í lokastöðu þá erum við með hlutstreng í s sem er í p.


- Ljóst er að alltaf þegar við erum í lokastöðu þá erum við með hlutstreng í s sem er í p.
- ► En eru þetta einu slíku hlutstrengirnir?

- Ljóst er að alltaf þegar við erum í lokastöðu þá erum við með hlutstreng í s sem er í p.
- ► En eru þetta einu slíku hlutstrengirnir?




- Ljóst er að alltaf þegar við erum í lokastöðu þá erum við með hlutstreng í s sem er í p.
- ► En eru þetta einu slíku hlutstrengirnir?

"bcb"




- Ljóst er að alltaf þegar við erum í lokastöðu þá erum við með hlutstreng í s sem er í p.
- ► En eru þetta einu slíku hlutstrengirnir?


"bcb"




- Ljóst er að alltaf þegar við erum í lokastöðu þá erum við með hlutstreng í s sem er í p.
- ► En eru þetta einu slíku hlutstrengirnir?




- Ljóst er að alltaf þegar við erum í lokastöðu þá erum við með hlutstreng í s sem er í p.
- ► En eru þetta einu slíku hlutstrengirnir?




- Ljóst er að alltaf þegar við erum í lokastöðu þá erum við með hlutstreng í s sem er í p.
- ► En eru þetta einu slíku hlutstrengirnir?



- Ljóst er að alltaf þegar við erum í lokastöðu þá erum við með hlutstreng í s sem er í p.
- ► En eru þetta einu slíku hlutstrengirnir?




- Ljóst er að alltaf þegar við erum í lokastöðu þá erum við með hlutstreng í s sem er í p.
- ► En eru þetta einu slíku hlutstrengirnir?




Nei, við þurfum líka, í hverju skrefi, að athuga hvort við getum komist í lokastöðu ef við ferðumst eftir bakstrengsleggjum.

- Ljóst er að alltaf þegar við erum í lokastöðu þá erum við með hlutstreng í s sem er í p.
- ► En eru þetta einu slíku hlutstrengirnir?



- Nei, við þurfum líka, í hverju skrefi, að athuga hvort við getum komist í lokastöðu ef við ferðumst eftir bakstrengsleggjum.
- ► Til að koma í vega fyrir að tímaflækjan verði of slæm þá notum við aftur kvika bestun.

- Ljóst er að alltaf þegar við erum í lokastöðu þá erum við með hlutstreng í s sem er í p.
- ► En eru þetta einu slíku hlutstrengirnir?



- Nei, við þurfum líka, í hverju skrefi, að athuga hvort við getum komist í lokastöðu ef við ferðumst eftir bakstrengsleggjum.
- ► Til að koma í vega fyrir að tímaflækjan verði of slæm þá notum við aftur kvika bestun.
- Við bætum í raun leggjum inn í tréð, sem við köllum lokaleggi (e. exit link).

▶ Í útfærslunni munum við notast við þrjú hjálparföll.

- ▶ Í útfærslunni munum við notast við þrjú hjálparföll.
- Fyrsta heitir trie_step(...) sem er notað til að ferðast um stöðuvélina.

- Í útfærslunni munum við notast við þrjú hjálparföll.
- ► Fyrsta heitir trie_step(...) sem er notað til að ferðast um stöðuvélina.
- Annað heitir trie_suffix(...) sem er notað til að finna bakstrengsleggi.

- ▶ Í útfærslunni munum við notast við þrjú hjálparföll.
- Fyrsta heitir trie_step(...) sem er notað til að ferðast um stöðuvélina.
- Annað heitir trie_suffix(...) sem er notað til að finna bakstrengsleggi.
- Þriðja heitir trie_exit(...) sem er notað til að finna lokaleggina.

- Í útfærslunni munum við notast við þrjú hjálparföll.
- Fyrsta heitir trie_step(...) sem er notað til að ferðast um stöðuvélina.
- Annað heitir trie_suffix(...) sem er notað til að finna bakstrengsleggi.
- Priðja heitir trie_exit(...) sem er notað til að finna lokaleggina.
- ▶ Öll þessi föll eru endurkvæm og notast við minnun.

```
5 #define ALPHABET 128
 6 #define MAXN 1000000
 7 typedef struct { int v, n; } listnode;
 8 typedef struct { int t[ALPHABET], I, e, p, c, d; } trienode;
 9 typedef struct { int s, r, l; trienode m[MAXN + 1]; listnode w[MAXN];} trie;
10 int val(char c) { return c; }
   int list node(trie *t, int v, int n)
12 {
13
         t \rightarrow w[t \rightarrow 1]. v = v, t \rightarrow w[t \rightarrow 1]. n = n;
14
         return t\rightarrow l++;
15 }
16 int trie node(trie *t, int p, int c)
17 {
18
         int i:
19
         for (i = 0; i < ALPHABET; i++) t->m[t->s].t[i] = -1;
20
         t \rightarrow m[t \rightarrow s]. l = -1, t \rightarrow m[t \rightarrow s]. e = -1, t \rightarrow m[t \rightarrow s]. p = p,
              t \rightarrow m[t \rightarrow s].c = c, t \rightarrow m[t \rightarrow s].d = -1;
21
22
         return t->s++:
23 }
24 void trie init(trie *t) { t\rightarrow s = t\rightarrow l = 0, t\rightarrow r = trie node(t, -1, -1); }
25
26 void trie insert(trie *t, char *s, int x)
27
28
         int h:
29
         for (h = t \rightarrow r; *s; h = t \rightarrow m[h].t[val(*s++)])
30
              if (t->m[h].t[val(*s)] == -1)
31
                   t\rightarrow m[h].t[val(*s)] = trie node(t, h, val(*s));
         t\rightarrow m[h].l = list node(t, x, t\rightarrow m[h].l);
32
33 }
```

```
35 int trie step(trie*, int, int);
   int trie suffix (trie *t, int h)
37
   {
         if (t->m[h].d != -1) return t->m[h].d;
38
         if (h = t \rightarrow r \mid | t \rightarrow m[h].p = t \rightarrow r) return t \rightarrow m[h].d = t \rightarrow r;
39
40
         return t->m[h].d = trie step(t, trie suffix(t, t->m[h].p), t->m[h].c);
41 }
42
43
   int trie step(trie *t, int h, int c)
44
   {
45
         if (t->m[h].t[c] != -1) return t->m[h].t[c];
46
         return t\rightarrow m[h].t[c] = h == t\rightarrow r ? t\rightarrow r :
47
             trie_step(t, trie_suffix(t, h), c);
48 }
49
50
   int trie exit(trie *t, int h)
51 {
52
         if (t\rightarrow m[h].e!=-1) return t\rightarrow m[h].e;
53
         if (h = 0 \mid | t-m[h]. \mid != -1) return t-m[h]. e = h;
         return t\rightarrow m[h].e = trie exit(t, trie suffix(t, h));
54
55 }
```

```
57 trie t:
   int aho corasick(char *s, char **p, int m)
59
   {
60
        trie init(&t);
61
        int \overline{h}, i, j, k, w, \lfloor \lfloor m \rfloor \rfloor;
        for (i = 0; i < m; i++) | [i] = strlen(p[i]);
62
63
        for (i = 0; i < m; i++) trie insert(&t, p[i], i);
64
        printf("
        for (i = 0; i < strlen(s); i++) printf("%d", i%10); printf("\n");
65
66
        printf("searching in %s\n", s);
        for (i = 0, j = 0, h = t.r; j + +)
67
68
            k = trie exit(&t. h):
69
70
            while (t.m[k]. | != -1)
71
72
                for (w = t.m[k].l; w != -1; w = t.w[w].n)
73
74
                     printf(" '%s' found at index %d\n",
                              p[t.w[w].v]. i - [[t.w[w].v]]:
75
76
                k = trie exit(&t, trie suffix(&t, k));
77
78
            h = trie step(&t, h, val(*s));
79
80
            if (*s++== '\0') break;
81
82
        return i:
83 }
```

► Gerum ráð fyrir að strengirnar í *p* komi fyrir *k* sinnum í *s*.

- ► Gerum ráð fyrir að strengirnar í *p* komi fyrir *k* sinnum í *s*.
- ightharpoonup Þá er tímaflækjan $\mathcal{O}($

- ► Gerum ráð fyrir að strengirnar í *p* komi fyrir *k* sinnum í *s*.
- ▶ Þá er tímaflækjan $\mathcal{O}(|s| + |\Sigma| \cdot |p| + k)$.

- ► Gerum ráð fyrir að strengirnar í *p* komi fyrir *k* sinnum í *s*.
- ▶ Þá er tímaflækjan $\mathcal{O}(|s| + |\Sigma| \cdot |p| + k)$.
- ► Ef við höfum bara áhuga á að finna töluna *k* getum við breytt trie_exit(...) þannig að það reikni fjölda lokastaða á leiðinni að rót eftir bakstrengsleggjum.

- Gerum ráð fyrir að strengirnar í p komi fyrir k sinnum í s.
- ▶ Þá er tímaflækjan $\mathcal{O}(|s| + |\Sigma| \cdot |p| + k)$.
- ► Ef við höfum bara áhuga á að finna töluna *k* getum við breytt trie_exit(...) þannig að það reikni fjölda lokastaða á leiðinni að rót eftir bakstrengsleggjum.
- ightharpoonup Þá verður tímaflækjan $\mathcal{O}($

- ► Gerum ráð fyrir að strengirnar í *p* komi fyrir *k* sinnum í *s*.
- ▶ Þá er tímaflækjan $\mathcal{O}(|s| + |\Sigma| \cdot |p| + k)$.
- ► Ef við höfum bara áhuga á að finna töluna k getum við breytt trie_exit(...) þannig að það reikni fjölda lokastaða á leiðinni að rót eftir bakstrengsleggjum.
- Þá verður tímaflækjan $\mathcal{O}(|s| + |\Sigma| \cdot |p|)$.

- ► Gerum ráð fyrir að strengirnar í *p* komi fyrir *k* sinnum í *s*.
- ▶ Þá er tímaflækjan $\mathcal{O}(|s| + |\Sigma| \cdot |p| + k)$.
- ► Ef við höfum bara áhuga á að finna töluna *k* getum við breytt trie_exit(...) þannig að það reikni fjölda lokastaða á leiðinni að rót eftir bakstrengsleggjum.
- ▶ Þá verður tímaflækjan $\mathcal{O}(|s| + |\Sigma| \cdot |p|)$.
- Takið eftir að ef stafrófið er takmarkað þá er seinni tímaflækjan línuleg.