## Reiknirit Ahos og Corasicks (1975)

Bergur Snorrason

12. apríl 2023

▶ Gerum ráð fyrir að við séum með stafróf  $\Sigma$ , streng s og lista af n strengjum p, þar sem j-ti strengurinn kallast  $p_i$ .

- ▶ Gerum ráð fyrir að við séum með stafróf  $\Sigma$ , streng s og lista af n strengjum p, þar sem j-ti strengurinn kallast  $p_i$ .
- ▶ Látum |s| tákna lengd strengsins s og  $|p| = |p_1| + \cdots + |p_n|$ .

- ▶ Gerum ráð fyrir að við séum með stafróf  $\Sigma$ , streng s og lista af n strengjum p, þar sem j-ti strengurinn kallast  $p_i$ .
- ▶ Látum |s| tákna lengd strengsins s og  $|p| = |p_1| + \cdots + |p_n|$ .
- ▶ Við viljum finna alla hlutstrengi s sem eru í listanum p.

- ▶ Gerum ráð fyrir að við séum með stafróf  $\Sigma$ , streng s og lista af n strengjum p, þar sem j-ti strengurinn kallast  $p_i$ .
- ▶ Látum |s| tákna lengd strengsins s og  $|p| = |p_1| + \cdots + |p_n|$ .
- ▶ Við viljum finna alla hlutstrengi s sem eru í listanum p.
- ▶ Við getum notað reiknirit Knuths, Morrisar og Pratts *n* sinnum.

- ▶ Gerum ráð fyrir að við séum með stafróf  $\Sigma$ , streng s og lista af n strengjum p, þar sem j-ti strengurinn kallast  $p_i$ .
- ▶ Látum |s| tákna lengd strengsins s og  $|p| = |p_1| + \cdots + |p_n|$ .
- ▶ Við viljum finna alla hlutstrengi s sem eru í listanum p.
- ▶ Við getum notað reiknirit Knuths, Morrisar og Pratts *n* sinnum.
- ▶ Þessi aðferð hefur tímaflækjuna  $\mathcal{O}(n \cdot |s| + |p|)$ .

- ▶ Gerum ráð fyrir að við séum með stafróf  $\Sigma$ , streng s og lista af n strengjum p, þar sem j-ti strengurinn kallast  $p_i$ .
- ▶ Látum |s| tákna lengd strengsins s og  $|p| = |p_1| + \cdots + |p_n|$ .
- ▶ Við viljum finna alla hlutstrengi s sem eru í listanum p.
- ▶ Við getum notað reiknirit Knuths, Morrisar og Pratts *n* sinnum.
- ▶ Þessi aðferð hefur tímaflækjuna  $\mathcal{O}(n \cdot |s| + |p|)$ .
- Reiknirit Ahos og Corasicks bætir þetta.

ightharpoonup Byrjum á að setja all strengina í p inn í forstrengstré T.

- ightharpoonup Byrjum á að setja all strengina í p inn í forstrengstré T.
- ▶ Við viljum síðan búa til stöðuvél úr *T*.

- ightharpoonup Byrjum á að setja all strengina í p inn í forstrengstré T.
- ▶ Við viljum síðan búa til stöðuvél úr T.
- Hnútarnir í trénu eru stöðurnar, en okkur vantar að finna færslur fyrir hverja stöðu og bókstaf í Σ.

- **B**yrjum á að setja all strengina í p inn í forstrengstré T.
- ▶ Við viljum síðan búa til stöðuvél úr T.
- Hnútarnir í trénu eru stöðurnar, en okkur vantar að finna færslur fyrir hverja stöðu og bókstaf í Σ.
- ▶ Gerum ráð fyrir að við séum í hnút v í T og viljum færast fyrir staf c í  $\Sigma$ .

- **b** Byrjum á að setja all strengina í p inn í forstrengstré T.
- ▶ Við viljum síðan búa til stöðuvél úr T.
- Hnútarnir í trénu eru stöðurnar, en okkur vantar að finna færslur fyrir hverja stöðu og bókstaf í Σ.
- ▶ Gerum ráð fyrir að við séum í hnút v í T og viljum færast fyrir staf c í  $\Sigma$ .
- ► Ef það er leggur í *T* úr *v* merktur með *c* þá ferðumst við eftir honum.

- **b** Byrjum á að setja all strengina í p inn í forstrengstré T.
- ▶ Við viljum síðan búa til stöðuvél úr T.
- Hnútarnir í trénu eru stöðurnar, en okkur vantar að finna færslur fyrir hverja stöðu og bókstaf í Σ.
- ▶ Gerum ráð fyrir að við séum í hnút v í T og viljum færast fyrir staf c í  $\Sigma$ .
- ► Ef það er leggur í *T* úr *v* merktur með *c* þá ferðumst við eftir honum.
- Annars þurfum við að fara aftur í hnút w þannig að strengurinn sem svarar til w er bakstrengur strengsins sem svarar til v.

- **b** Byrjum á að setja all strengina í p inn í forstrengstré T.
- Við viljum síðan búa til stöðuvél úr T.
- Hnútarnir í trénu eru stöðurnar, en okkur vantar að finna færslur fyrir hverja stöðu og bókstaf í Σ.
- ▶ Gerum ráð fyrir að við séum í hnút v í T og viljum færast fyrir staf c í  $\Sigma$ .
- Ef það er leggur í T úr v merktur með c þá ferðumst við eftir honum.
- Annars þurfum við að fara aftur í hnút w þannig að strengurinn sem svarar til w er bakstrengur strengsins sem svarar til v.
- ▶ Við viljum hafa strenginn w sem lengstan (með öðrum orðum viljum við fara sem styst aftur).

- ightharpoonup Byrjum á að setja all strengina í p inn í forstrengstré T.
- Við viljum síðan búa til stöðuvél úr T.
- Hnútarnir í trénu eru stöðurnar, en okkur vantar að finna færslur fyrir hverja stöðu og bókstaf í Σ.
- ▶ Gerum ráð fyrir að við séum í hnút v í T og viljum færast fyrir staf c í  $\Sigma$ .
- Ef það er leggur í T úr v merktur með c þá ferðumst við eftir honum.
- Annars þurfum við að fara aftur í hnút w þannig að strengurinn sem svarar til w er bakstrengur strengsins sem svarar til v.
- ▶ Við viljum hafa strenginn w sem lengstan (með öðrum orðum viljum við fara sem styst aftur).
- ▶ Í hvern hnút bætum við við legg sem svarar til slíkrar færslu.

- ightharpoonup Byrjum á að setja all strengina í p inn í forstrengstré T.
- Við viljum síðan búa til stöðuvél úr T.
- Hnútarnir í trénu eru stöðurnar, en okkur vantar að finna færslur fyrir hverja stöðu og bókstaf í Σ.
- ▶ Gerum ráð fyrir að við séum í hnút v í T og viljum færast fyrir staf c í  $\Sigma$ .
- Ef það er leggur í T úr v merktur með c þá ferðumst við eftir honum.
- Annars þurfum við að fara aftur í hnút w þannig að strengurinn sem svarar til w er bakstrengur strengsins sem svarar til v.
- ▶ Við viljum hafa strenginn w sem lengstan (með öðrum orðum viljum við fara sem styst aftur).
- Í hvern hnút bætum við við legg sem svarar til slíkrar færslu.
- ▶ Við köllum þessa leggi bakstrengsleggi (e. suffix links).

- ightharpoonup Byrjum á að setja all strengina í p inn í forstrengstré T.
- Við viljum síðan búa til stöðuvél úr T.
- Hnútarnir í trénu eru stöðurnar, en okkur vantar að finna færslur fyrir hverja stöðu og bókstaf í Σ.
- ▶ Gerum ráð fyrir að við séum í hnút v í T og viljum færast fyrir staf c í  $\Sigma$ .
- Ef það er leggur í T úr v merktur með c þá ferðumst við eftir honum.
- Annars þurfum við að fara aftur í hnút w þannig að strengurinn sem svarar til w er bakstrengur strengsins sem svarar til v.
- ▶ Við viljum hafa strenginn w sem lengstan (með öðrum orðum viljum við fara sem styst aftur).
- ▶ Í hvern hnút bætum við við legg sem svarar til slíkrar færslu.
- ▶ Við köllum þessa leggi bakstrengsleggi (e. suffix links).
- Takið eftir að þeir eru í raun óháðir bókstafnum c.

- ightharpoonup Byrjum á að setja all strengina í p inn í forstrengstré T.
- ▶ Við viljum síðan búa til stöðuvél úr T.
- Hnútarnir í trénu eru stöðurnar, en okkur vantar að finna færslur fyrir hverja stöðu og bókstaf í Σ.
- ▶ Gerum ráð fyrir að við séum í hnút v í T og viljum færast fyrir staf c í  $\Sigma$ .
- ► Ef það er leggur í *T* úr *v* merktur með *c* þá ferðumst við eftir honum.
- Annars þurfum við að fara aftur í hnút w þannig að strengurinn sem svarar til w er bakstrengur strengsins sem svarar til v.
- ▶ Við viljum hafa strenginn w sem lengstan (með öðrum orðum viljum við fara sem styst aftur).
- Í hvern hnút bætum við við legg sem svarar til slíkrar færslu.
- Við köllum þessa leggi bakstrengsleggi (e. suffix links).
- Takið eftir að þeir eru í raun óháðir bókstafnum c.
- ► Við látum bakstrengslegg rótarinn benda á sjálfa sig.

► Hvernig finnum við alla bakstrengsleggina?

- ► Hvernig finnum við alla bakstrengsleggina?
- ► Við notum kvika bestun.


- ► Hvernig finnum við alla bakstrengsleggina?
- Við notum kvika bestun.
- Látum f(w, c) tákna færslu úr stöðu w með staf c og g(w) tákna bakstrengslegg w.


- Hvernig finnum við alla bakstrengsleggina?
- Við notum kvika bestun.
- Látum f(w, c) tákna færslu úr stöðu w með staf c og g(w) tákna bakstrengslegg w.
- Gerum einnig ráð fyrir að foreldri v sé p og f(p, a) = v.


- Hvernig finnum við alla bakstrengsleggina?
- Við notum kvika bestun.
- Látum f(w, c) tákna færslu úr stöðu w með staf c og g(w) tákna bakstrengslegg w.
- Gerum einnig ráð fyrir að foreldri v sé p og f(p, a) = v.
- Við sjáum þá að g(v) = f(g(p), a).


- Hvernig finnum við alla bakstrengsleggina?
- Við notum kvika bestun.
- Látum f(w, c) tákna færslu úr stöðu w með staf c og g(w) tákna bakstrengslegg w.
- Gerum einnig ráð fyrir að foreldri v sé p og f(p, a) = v.
- Við sjáum þá að g(v) = f(g(p), a).
- Með öðrum orðum förum við upp í foreldrið, ferðumst eftir bakstrenglegg þaðan og færum okkur í stöðuvélinni eftir a.


- Hvernig finnum við alla bakstrengsleggina?
- Við notum kvika bestun.
- Látum f(w, c) tákna færslu úr stöðu w með staf c og g(w) tákna bakstrengslegg w.
- Gerum einnig ráð fyrir að foreldri v sé p og f(p, a) = v.
- Við sjáum þá að g(v) = f(g(p), a).
- Með öðrum orðum förum við upp í foreldrið, ferðumst eftir bakstrenglegg þaðan og færum okkur í stöðuvélinni eftir a.
- Við höfum þá rakningarformúlu sem við getum notað til að reikna bakstrengshlekkina.





































▶ Í T merkjum við lokastöður þar sem strengir enda.

- ▶ Í T merkjum við lokastöður þar sem strengir enda.
- ▶ Við ferðumst svo í gegnum strenginn s og hliðrum stöðvélinni miðað við stafina í s.


#### "abcdcdeaaabcdeabcxab"




#### "abcdcdeaaabcdeabcxab"




"bcdcdeaaabcdeabcxab"




### "cdcdeaaabcdeabcxab"




### "dcdeaaabcdeabcxab"




### "cdeaaabcdeabcxab"




### "cdeaaabcdeabcxab"




### "cdeaaabcdeabcxab"




"deaaabcdeabcxab"




## "eaaabcdeabcxab"




### "aaabcdeabcxab"




### "aabcdeabcxab"




### "aabcdeabcxab"




### "abcdeabcxab"




### "abcdeabcxab"




## "bcdeabcxab"




## "cdeabcxab"




"deabcxab"




"eabcxab"




"eabcxab"




## "abcxab"




## "abcxab"




# "bcxab"




"cxab"



































Ljóst er að alltaf þegar við erum í lokastöðu þá erum við með hlutstreng í s sem er í p.

- Ljóst er að alltaf þegar við erum í lokastöðu þá erum við með hlutstreng í s sem er í p.
- ► En eru þetta einu slíku hlutstrengirnir?


- Ljóst er að alltaf þegar við erum í lokastöðu þá erum við með hlutstreng í s sem er í p.
- ► En eru þetta einu slíku hlutstrengirnir?




- Ljóst er að alltaf þegar við erum í lokastöðu þá erum við með hlutstreng í s sem er í p.
- ► En eru þetta einu slíku hlutstrengirnir?




- Ljóst er að alltaf þegar við erum í lokastöðu þá erum við með hlutstreng í s sem er í p.
- ► En eru þetta einu slíku hlutstrengirnir?




- Ljóst er að alltaf þegar við erum í lokastöðu þá erum við með hlutstreng í s sem er í p.
- ► En eru þetta einu slíku hlutstrengirnir?




- Ljóst er að alltaf þegar við erum í lokastöðu þá erum við með hlutstreng í s sem er í p.
- ► En eru þetta einu slíku hlutstrengirnir?




- Ljóst er að alltaf þegar við erum í lokastöðu þá erum við með hlutstreng í s sem er í p.
- ► En eru þetta einu slíku hlutstrengirnir?



- Ljóst er að alltaf þegar við erum í lokastöðu þá erum við með hlutstreng í s sem er í p.
- ► En eru þetta einu slíku hlutstrengirnir?




- Ljóst er að alltaf þegar við erum í lokastöðu þá erum við með hlutstreng í s sem er í p.
- En eru þetta einu slíku hlutstrengirnir?




Nei, við þurfum líka, í hverju skrefi, að athuga hvort við getum komist í lokastöðu ef við ferðumst eftir bakstrengsleggjum.

- Ljóst er að alltaf þegar við erum í lokastöðu þá erum við með hlutstreng í s sem er í p.
- En eru þetta einu slíku hlutstrengirnir?



- Nei, við þurfum líka, í hverju skrefi, að athuga hvort við getum komist í lokastöðu ef við ferðumst eftir bakstrengsleggjum.
- ► Til að koma í veg fyrir að tímaflækjan verði of slæm þá notum við aftur kvika bestun.

- Ljóst er að alltaf þegar við erum í lokastöðu þá erum við með hlutstreng í s sem er í p.
- En eru þetta einu slíku hlutstrengirnir?



- Nei, við þurfum líka, í hverju skrefi, að athuga hvort við getum komist í lokastöðu ef við ferðumst eftir bakstrengsleggjum.
- Til að koma í veg fyrir að tímaflækjan verði of slæm þá notum við aftur kvika bestun.
- Við bætum í raun leggjum inn í tréð, sem við köllum lokaleggi (e. exit links).

Í útfærslunni munum við notast við þrjú hjálparföll.

- Í útfærslunni munum við notast við þrjú hjálparföll.
- ► Fyrsta heitir trie\_step(...) sem er notað til að ferðast um stöðuvélina.

- Í útfærslunni munum við notast við þrjú hjálparföll.
- Fyrsta heitir trie\_step(...) sem er notað til að ferðast um stöðuvélina.
- Annað heitir trie\_suffix(...) sem er notað til að finna bakstrengsleggi.

- Í útfærslunni munum við notast við þrjú hjálparföll.
- Fyrsta heitir trie\_step(...) sem er notað til að ferðast um stöðuvélina.
- Annað heitir trie\_suffix(...) sem er notað til að finna bakstrengsleggi.
- Priðja heitir trie\_exit(...) sem er notað til að finna lokaleggina.

- Í útfærslunni munum við notast við þrjú hjálparföll.
- Fyrsta heitir trie\_step(...) sem er notað til að ferðast um stöðuvélina.
- Annað heitir trie\_suffix(...) sem er notað til að finna bakstrengsleggi.
- Þriðja heitir trie\_exit(...) sem er notað til að finna lokaleggina.
- Dil þessi föll eru endurkvæm og notast við minnun.

```
5 #define ALPHABET 128
 6 #define MAXN 1000000
 7 typedef struct { int v, n; } listnode;
 8 typedef struct { int t[ALPHABET], I, e, p, c, d; } trienode;
 9 typedef struct { int s, r, l; trienode m[MAXN + 1]; listnode w[MAXN];} trie;
10 int val(char c) { return c; }
11 int list node(trie *t, int v, int n)
12 {
13
        t \rightarrow w[t \rightarrow 1].v = v, t \rightarrow w[t \rightarrow 1].n = n;
14
         return t->1++;
15 }
16 int trie node(trie *t, int p, int c)
17 {
18
        for (int i = 0; i < ALPHABET; i++) t->m[t->s].t[i] = -1;
19
        t \rightarrow m[t \rightarrow s]. l = t \rightarrow m[t \rightarrow s]. e = t \rightarrow m[t \rightarrow s]. d = -1;
20
             t->m[t->s].p = p, t->m[t->s].c = c,
21
         return t->s++;
22 }
23 void trie init(trie *t) { t\rightarrow s = t\rightarrow l = 0, t\rightarrow r = trie node(t, -1, -1); }
24
25 void trie_insert(trie *t, char *s, int x)
26
27
         int h:
28
         for (h = t \rightarrow r; *s; h = t \rightarrow m[h].t[val(*s++)])
29
              if (t->m[h].t[val(*s)] == -1)
30
                  t\rightarrow m[h].t[val(*s)] = trie node(t, h, val(*s));
31
        t\rightarrow m[h].l = list node(t, x, t\rightarrow m[h].l);
32 }
```

```
35 int trie suffix (trie *t, int h)
36 {
37
          if (t\rightarrow m[h].d!=-1) return t\rightarrow m[h].d;
          if (h = t \rightarrow r \mid t \rightarrow m[h], p = t \rightarrow r) return t \rightarrow m[h], d = t \rightarrow r;
38
          return t\rightarrow m[h].d = trie\_step(t, trie\_suffix(t, t\rightarrow m[h].p), t\rightarrow m[h].c);
39
40 }
41
42
    int trie step(trie *t, int h, int c)
    {
43
44
          if (t->m[h],t[c] != -1) return t->m[h],t[c];
45
          return t\rightarrow m[h].t[c] = h == t\rightarrow r ? t\rightarrow r :
46
               trie_step(t, trie_suffix(t, h), c);
47 }
48
49 int trie exit(trie *t, int h)
50 {
51
          if (t\rightarrow m[h].e!=-1) return t\rightarrow m[h].e;
52
          if (h == 0 \mid | t \rightarrow m[h]. \mid != -1) return t \rightarrow m[h]. e = h;
53
          return t\rightarrow m[h]. e = trie exit(t, trie suffix(t, h));
54 }
```

```
int aho corasick(char *s, char **p, int m)
58
   {
59
        trie init(&t);
60
        int \overline{h}, i, j, k, w, \lfloor \lfloor m \rfloor \rfloor;
        for (i = 0; i < m; i++) | [i] = strlen(p[i]);
61
        for (i = 0; i < m; i++) trie insert(&t, p[i], i);
62
63
        printf("
        for (i = 0; i < strlen(s); i++) printf("%d", i%10); printf("\n");
64
65
        printf("searching in %s\n", s);
66
        for (i = 0, j = 0, h = t.r; j + +)
67
68
            k = trie exit(&t, h);
69
             while (t \cdot m[k] \cdot l! = -1)
70
71
                 for (w = t.m[k].l; w != -1; w = t.w[w].n)
72
                      printf(" \%s' found at \%d\n", p[t.w[w].v], j - l[t.w[w].v]);
73
                 k = trie \ exit(&t, trie \ suffix(&t, k));
74
75
            h = trie step(&t, h, val(*s));
76
             if (*s++-='\setminus 0') break:
77
78
        return i:
79 }
80
81
   int main()
82 {
83
        int i, j, n;
```

► Gerum ráð fyrir að strengirnar í *p* komi fyrir *k* sinnum í *s*.

- ► Gerum ráð fyrir að strengirnar í *p* komi fyrir *k* sinnum í *s*.
- ightharpoonup Þá er tímaflækjan  $\mathcal{O}($

- ► Gerum ráð fyrir að strengirnar í *p* komi fyrir *k* sinnum í *s*.
- ▶ Þá er tímaflækjan  $\mathcal{O}(|s| + |\Sigma| \cdot |p| + k)$ .

- Gerum ráð fyrir að strengirnar í p komi fyrir k sinnum í s.
- ▶ Þá er tímaflækjan  $\mathcal{O}(|s| + |\Sigma| \cdot |p| + k)$ .
- ► Ef við höfum bara áhuga á að finna töluna *k* getum við breytt trie\_exit(...) þannig að það reikni fjölda lokastaða á leiðinni að rót eftir bakstrengsleggjum.

- Gerum ráð fyrir að strengirnar í p komi fyrir k sinnum í s.
- ▶ Þá er tímaflækjan  $\mathcal{O}(|s| + |\Sigma| \cdot |p| + k)$ .
- ► Ef við höfum bara áhuga á að finna töluna *k* getum við breytt trie\_exit(...) þannig að það reikni fjölda lokastaða á leiðinni að rót eftir bakstrengsleggjum.
- ightharpoonup Þá verður tímaflækjan  $\mathcal{O}($

- ► Gerum ráð fyrir að strengirnar í p komi fyrir k sinnum í s.
- ▶ Þá er tímaflækjan  $\mathcal{O}(|s| + |\Sigma| \cdot |p| + k)$ .
- ► Ef við höfum bara áhuga á að finna töluna *k* getum við breytt trie\_exit(...) þannig að það reikni fjölda lokastaða á leiðinni að rót eftir bakstrengsleggjum.
- Þá verður tímaflækjan  $\mathcal{O}(|s| + |\Sigma| \cdot |p|)$ .

- Gerum ráð fyrir að strengirnar í p komi fyrir k sinnum í s.
- ▶ Þá er tímaflækjan  $\mathcal{O}(|s| + |\Sigma| \cdot |p| + k)$ .
- ► Ef við höfum bara áhuga á að finna töluna *k* getum við breytt trie\_exit(...) þannig að það reikni fjölda lokastaða á leiðinni að rót eftir bakstrengsleggjum.
- ▶ Þá verður tímaflækjan  $\mathcal{O}(|s| + |\Sigma| \cdot |p|)$ .
- Takið eftir að ef stafrófið er takmarkað þá er seinni tímaflækjan línuleg.