Reiknirit Knuths, Morrisar og Pratts (1970)

Bergur Snorrason

3. apríl 2023

► Gefum okkur langan streng s og styttri streng p.

- ► Gefum okkur langan streng *s* og styttri streng *p*.
- ▶ Hvernig getum við fundið alla hlutstrengi s sem eru jafnir p.

- Gefum okkur langan streng s og styttri streng p.
- ▶ Hvernig getum við fundið alla hlutstrengi s sem eru jafnir p.
- ► Fyrsta sem manni dettur í hug er að bera p saman við alla hlutstrengi s af sömu lengd og p.

```
5 void frumstaed_strengjaleit(char* s, int n, char* p, int m, int *r)
6 {
7    int i, j;
8    for (i = 0; i < n; i++) r[i] = 0;
9    for (i = 0; i < n - m + 1; i++)
10    {
11        for (j = 0; j < m; j++) if (s[i + j] != p[j]) break;
12        if (j >= m) r[i] = 1;
13    }
14 }
```

▶ Gerum ráð fyrir að strengurinn s sé af lengd n og strengurinn p sé af lengd m.

- Gerum ráð fyrir að strengurinn s sé af lengd n og strengurinn p sé af lengd m.
- Fjöldi hlutstrengja í s að lengd m er n m + 1.

- Gerum ráð fyrir að strengurinn s sé af lengd n og strengurinn p sé af lengd m.
- Fjöldi hlutstrengja í s að lengd m er n m + 1.
- Strengjasamanburðurinn tekur línulegan tíma.

- Gerum ráð fyrir að strengurinn s sé af lengd n og strengurinn p sé af lengd m.
- Fjöldi hlutstrengja í s að lengd m er n m + 1.
- ► Strengjasamanburðurinn tekur línulegan tíma.
- Svo tímaflækja leitarinnar er $\mathcal{O}($

- Gerum ráð fyrir að strengurinn s sé af lengd n og strengurinn p sé af lengd m.
- Fjöldi hlutstrengja í s að lengd m er n m + 1.
- Strengjasamanburðurinn tekur línulegan tíma.
- ▶ Svo tímaflækja leitarinnar er $\mathcal{O}(nm m^2)$.

- Gerum ráð fyrir að strengurinn s sé af lengd n og strengurinn p sé af lengd m.
- Fjöldi hlutstrengja í s að lengd m er n m + 1.
- Strengjasamanburðurinn tekur línulegan tíma.
- ▶ Svo tímaflækja leitarinnar er $\mathcal{O}(nm m^2)$.
- ► Ef m = n/2 þá er $nm m^2 = n^2/2 n^2/4 = n^2/4$ tímaflækjan er í raun $\mathcal{O}($

- Gerum ráð fyrir að strengurinn s sé af lengd n og strengurinn p sé af lengd m.
- Fjöldi hlutstrengja í s að lengd m er n m + 1.
- Strengjasamanburðurinn tekur línulegan tíma.
- ▶ Svo tímaflækja leitarinnar er $\mathcal{O}(nm m^2)$.
- ► Ef m = n/2 þá er $nm m^2 = n^2/2 n^2/4 = n^2/4$ tímaflækjan er í raun $\mathcal{O}(n^2)$.

- Gerum ráð fyrir að strengurinn s sé af lengd n og strengurinn p sé af lengd m.
- Fjöldi hlutstrengja í s að lengd m er n m + 1.
- Strengjasamanburðurinn tekur línulegan tíma.
- ▶ Svo tímaflækja leitarinnar er $\mathcal{O}(nm m^2)$.
- ► Ef m = n/2 þá er $nm m^2 = n^2/2 n^2/4 = n^2/4$ tímaflækjan er í raun $\mathcal{O}(n^2)$.

- Gerum ráð fyrir að strengurinn s sé af lengd n og strengurinn p sé af lengd m.
- Fjöldi hlutstrengja í s að lengd m er n m + 1.
- Strengjasamanburðurinn tekur línulegan tíma.
- ▶ Svo tímaflækja leitarinnar er $\mathcal{O}(nm m^2)$.
- ► Ef m = n/2 þá er $nm m^2 = n^2/2 n^2/4 = n^2/4$ tímaflækjan er í raun $\mathcal{O}(n^2)$.
- Dæmi um leiðinlega strengi væri s = "aaaaaaaaaaaaaaaa" og p = "aaaaaaaab".
- Þessi aðferð virkar þó sæmilega ef strengirnir eru nógu óreglulegir.

- Gerum ráð fyrir að strengurinn s sé af lengd n og strengurinn p sé af lengd m.
- Fjöldi hlutstrengja í s að lengd m er n m + 1.
- Strengjasamanburðurinn tekur línulegan tíma.
- ▶ Svo tímaflækja leitarinnar er $\mathcal{O}(nm m^2)$.
- ► Ef m = n/2 þá er $nm m^2 = n^2/2 n^2/4 = n^2/4$ tímaflækjan er í raun $\mathcal{O}(n^2)$.
- Dæmi um leiðinlega strengi væri s = "aaaaaaaaaaaaaaaa" og p = "aaaaaaaab".
- Þessi aðferð virkar þó sæmilega ef strengirnir eru nógu óreglulegir.
- Dæmi um það hvenær þessi aðferð er góð er ef maður er að leita að orði í skáldsögu.

▶ Aðferðin er líka nógu góð ef $\mathcal{O}(n^2)$ er ekki of hægt.

- ▶ Aðferðin er líka nógu góð ef $\mathcal{O}(n^2)$ er ekki of hægt.
- ▶ Það er þó óþarfi að útfæra hana því hún fylgir með flestum forritunarmálum, til dæmis:

- ▶ Aðferðin er líka nógu góð ef $\mathcal{O}(n^2)$ er ekki of hægt.
- ▶ Það er þó óþarfi að útfæra hana því hún fylgir með flestum forritunarmálum, til dæmis:
 - ▶ Í string.híCerstrstr(..).

- ▶ Aðferðin er líka nógu góð ef $\mathcal{O}(n^2)$ er ekki of hægt.
- Það er þó óþarfi að útfæra hana því hún fylgir með flestum forritunarmálum, til dæmis:
 - ▶ Í string.híCer strstr(..).
 - ▶ Í string í C++ er find(..).

- ▶ Aðferðin er líka nógu góð ef $\mathcal{O}(n^2)$ er ekki of hægt.
- Það er þó óþarfi að útfæra hana því hún fylgir með flestum forritunarmálum, til dæmis:
 - ▶ Í string.híCerstrstr(..).
 - ▶ Í string í C++ er find(..).
 - ▶ Í String í Java er indexOf(..).

- ▶ Aðferðin er líka nógu góð ef $\mathcal{O}(n^2)$ er ekki of hægt.
- Það er þó óþarfi að útfæra hana því hún fylgir með flestum forritunarmálum, til dæmis:
 - ▶ Í string.híCer strstr(..).
 - ▶ Í string í C++ er find(..).
 - ▶ Í String í Java er indexOf(..).
- Munið bara að ef $n > 10^4$ er þetta yfirleitt of hægt.

▶ Við getum bætt tímaflækjun með því að nota svokallað forstrengsfall (e. prefix function) strengsins a.

- ▶ Við getum bætt tímaflækjun með því að nota svokallað forstrengsfall (e. prefix function) strengsins a.
- Forstrengsfallið f er gefið með $f(j) = \max\{k \in \mathbb{N}: k < |a|, a[1, k] = a[j k + 1, j]\}.$

- ▶ Við getum bætt tímaflækjun með því að nota svokallað forstrengsfall (e. prefix function) strengsins a.
- Forstrengsfallið f er gefið með $f(j) = \max\{k \in \mathbb{N}: k < |a|, a[1, k] = a[j k + 1, j]\}.$
- Sjáum fyrst að þetta fall uppfyllir $f(j+1) \le f(j) + 1$.

- Við getum bætt tímaflækjun með því að nota svokallað forstrengsfall (e. prefix function) strengsins a.
- Forstrengsfallið f er gefið með $f(j) = \max\{k \in \mathbb{N} : k < |a|, a[1, k] = a[j k + 1, j]\}.$
- ▶ Sjáum fyrst að þetta fall uppfyllir $f(j+1) \le f(j) + 1$.
- Látum k = f(j) og sjáum að ef a[j+1] = a[k] þá er f(j+1) = k+1.

- Við getum bætt tímaflækjun með því að nota svokallað forstrengsfall (e. prefix function) strengsins a.
- Forstrengsfallið f er gefið með $f(j) = \max\{k \in \mathbb{N} : k < |a|, a[1, k] = a[j k + 1, j]\}.$
- ▶ Sjáum fyrst að þetta fall uppfyllir $f(j+1) \le f(j) + 1$.
- Látum k = f(j) og sjáum að ef a[j+1] = a[k] þá er f(j+1) = k+1.
- ▶ Ef $a[j+1] \neq a[k]$ þá þurfum við að minnka k þangað til við fáum jöfnuð.

- Við getum bætt tímaflækjun með því að nota svokallað forstrengsfall (e. prefix function) strengsins a.
- Forstrengsfallið f er gefið með $f(j) = \max\{k \in \mathbb{N} : k < |a|, a[1, k] = a[j k + 1, j]\}.$
- ▶ Sjáum fyrst að þetta fall uppfyllir $f(j+1) \le f(j) + 1$.
- Látum k = f(j) og sjáum að ef a[j+1] = a[k] þá er f(j+1) = k+1.
- ► Ef $a[j+1] \neq a[k]$ þá þurfum við að minnka k þangað til við fáum jöfnuð.
- Við minnkum k með því að láta k' = f(k-1).

```
12 void prefix_function(char *a, int *b)
13 {
14     int i, j, m = strlen(a);
15     for (i = 0, j = b[0] = -1; i < m; b[++i] = ++j)
16         while (j >= 0 && a[i] != a[j]) j = b[j];
17 }
```

► Takið eftir að hver ítrun innri lykkjanna svarar til einnar ítrunar ytri lykkjanna.

- ► Takið eftir að hver ítrun innri lykkjanna svarar til einnar ítrunar ytri lykkjanna.
- Svo innri lykkjan keyrir, í heildina, ekki oftar en ytri lykkjan.

- Takið eftir að hver ítrun innri lykkjanna svarar til einnar ítrunar ytri lykkjanna.
- Svo innri lykkjan keyrir, í heildina, ekki oftar en ytri lykkjan.
- \triangleright Því er tímaflækjan í heildina $\mathcal{O}(\)$ syfir streng af lengd n.

- Takið eftir að hver ítrun innri lykkjanna svarar til einnar ítrunar ytri lykkjanna.
- Svo innri lykkjan keyrir, í heildina, ekki oftar en ytri lykkjan.
- \triangleright Því er tímaflækjan í heildina $\mathcal{O}(n)$ syfir streng af lengd n.

► En hvernig getum við notað forstrengsfallið til að framkvæma strengjaleit?

- ► En hvernig getum við notað forstrengsfallið til að framkvæma strengjaleit?
- Gerum ráð fyrir að við séum að leit að streng p í stærri streng s.

- ► En hvernig getum við notað forstrengsfallið til að framkvæma strengjaleit?
- Gerum ráð fyrir að við séum að leit að streng p í stærri streng s.
- Látum þá $a = p + "\alpha" + s$, þar sem + táknar samskeytingu strengja og α er stafur sem er hvorki í p né s.

- ► En hvernig getum við notað forstrengsfallið til að framkvæma strengjaleit?
- Gerum ráð fyrir að við séum að leit að streng p í stærri streng s.
- Látum þá $a = p + "\alpha" + s$, þar sem + táknar samskeytingu strengja og α er stafur sem er hvorki í p né s.
- ▶ Við látum svo f vera forstrengsfall strengsins a.

- ► En hvernig getum við notað forstrengsfallið til að framkvæma strengjaleit?
- Gerum ráð fyrir að við séum að leit að streng p í stærri streng s.
- Látum þá $a = p + "\alpha" + s$, þar sem + táknar samskeytingu strengja og α er stafur sem er hvorki í p né s.
- ▶ Við látum svo f vera forstrengsfall strengsins a.
- ▶ Við höfum þá að $f \le |p|$ og f(j) = |p| þá og því aðeins að j > |p| og hlutstrengurinn í s sem byrjar á vísi j |p| 1 og er |p| af lengd er sá sami og p.

```
12 void prefix function(char *a, int *b)
13 {
14
       int i, j, m = strlen(a);
15
       for (i = 0, i = b[0] = -1; i < m; b[++i] = ++i)
16
           while (i >= 0 \&\& a[i] != a[j]) j = b[j];
17 }
18
19
  void kmp(char *s, char *p, int *r)
20
  {
21
       int i, j, n = strlen(s), m = strlen(p), b[n + m + 2];
22
       char a[n+m+2];
23
       strcpy(a, p), strcat(a, "\n"), strcat(a, s);
24
       prefix function(a, b);
       for (i = 0; i < n; i++) r[i] = i < n-m+1 & b[i+2*m+1] >= m;
25
26 }
```

▶ Gerum ráð fyrir að |s| = n og |p| = m.

- ▶ Gerum ráð fyrir að |s| = n og |p| = m.
- ▶ Pá er |a| = n + m + 1, svo tímaflækjan er $\mathcal{O}($

- ▶ Gerum ráð fyrir að |s| = n og |p| = m.
- ▶ Þá er |a| = n + m + 1, svo tímaflækjan er $\mathcal{O}(n + m)$.